



INSTITUTO POLITECNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO



Práctica 2:

ANÁLISIS DE DIFERENTES CONJUNTOS DE DATOS DE ENTRADA PARA LOS MÉTODOS DE APRENDIZAJE AUTOMÁTICO

Inteligencia Artificial

Profra. Vanessa Alejandra Camacho Vázquez

Grupo: 6CM3

Nombres de los integrantes:

- Aguirre Lanto Víctor Manuel
- Gasca Fragoso Pedro
- Guevara Badillo Areli Alejandra
- Montiel Toro Arael de Jesús
- Ramírez Lozano Gael Martin

Notebook: [Practica no.2](#)

Viernes, 19 de septiembre, 2025

CONTENIDO

IMPORTACIÓN DE DATASETS	3
CONJUNTO DE DATOS DEL DATASET DE CÁNCER DE SENO	3
CONJUNTO DE DATOS DEL DATASET DE IRIS.....	4
CONJUNTO DE DATOS DEL DATASET DE DIABETES	5
CONJUNTO DE DATOS DEL DATASET DE VINOS	6
INFORMACIÓN DE LOS DATOS DE ENTRADAS.....	6
CONJUNTO DE DATOS DEL DATASET DE CÁNCER DE SENO	7
CONJUNTO DE DATOS DEL DATASET DE IRIS.....	9
CONJUNTO DE DATOS DEL DATASET DE DIABETES	11
CONJUNTO DE DATOS DEL DATASET DE VINOS	13
GRÁFICAS DEL CONJUNTO DE DATOS	15
CONJUNTO DE DATOS DEL DATASET DE CÁNCER DE SENO	15
CONJUNTO DE DATOS DEL DATASET DE IRIS.....	15
CONJUNTO DE DATOS DEL DATASET DE DIABETES	16
CONJUNTO DE DATOS DEL DATASET DE VINO	16
CONCLUSIONES	17
AGUIRRE LANTO VÍCTOR MANUEL.....	17
GASCA FRAGOSO PEDRO	17
GUEVARA BADILLO ARELI ALEJANDRA	17
MONTIEL TORO ARAEL DE JESÚS.....	18
RAMÍREZ LOZANO GAEI MARTIN.....	18

IMPORTACIÓN DE DATASETS

Conjunto de datos del dataset de Cáncer de Seno

Descripción del datasets

El conjunto de datos **Cáncer de Mama de Wisconsin** contiene 569 muestras con 30 características numéricas cada una. Estas características, como el radio, la textura y la suavidad, se calcularon a partir de imágenes digitalizadas de aspirados de masas mamarias. El objetivo es una tarea de **clasificación binaria** para predecir si una masa es **maligna** o **benigna**.

[illegible]

Conjunto de datos del dataset de Iris

Descripción del datasets

El conjunto de datos **Iris** es un clásico para la **clasificación multiclase**. Contiene 150 muestras, cada una con 4 características numéricas que miden la longitud y el ancho del sépalo y del pétalo de flores de iris. El objetivo es clasificar cada flor en una de las tres especies: **Setosa, Versicolour y Virginica**.

[illegible]

Conjunto de datos del dataset de Diabetes

Descripción del datasets

El conjunto de datos **Diabetes** se utiliza para tareas de **regresión**. Contiene datos de 442 pacientes, con 10 variables predictoras para cada uno, como edad, sexo, índice de masa corporal y seis mediciones de suero sanguíneo. El objetivo es predecir la progresión de la enfermedad de la diabetes un año después de la medición inicial.

```
#Se importa el dataset de diabetes
from sklearn import datasets
dataset3 = datasets.load_diabetes()
print(dataset3)
```

```
{'data': array([[ 0.03807591,  0.05068012,  0.06169621, ..., -0.00259226,
  0.01990749, -0.01764613],
 [ -0.00188202, -0.04464164, -0.05147406, ..., -0.03949338,
 -0.06833155, -0.09220405],
 [ 0.08529891,  0.05068012,  0.04445121, ..., -0.00259226,
  0.00286131, -0.02593034],
 ...,
 [ 0.04170844,  0.05068012, -0.01590626, ..., -0.01107952,
 -0.04688253,  0.01549073],
 [ -0.04547248, -0.04464164,  0.03906215, ...,  0.02655962,
  0.04452873, -0.02593034],
 [ -0.04547248, -0.04464164, -0.0730303 , ..., -0.03949338,
 -0.00422151,  0.00306441]], 'target': array([151., 75., 141., 206., 135., 97., 138., 63., 110., 310., 101.,
 69., 179., 185., 118., 171., 166., 144., 97., 168., 68., 49.,
 68., 245., 184., 202., 137., 85., 131., 283., 129., 59., 341.,
 87., 65., 102., 265., 276., 252., 90., 100., 55., 61., 92.,
 259., 53., 190., 142., 75., 142., 155., 225., 59., 104., 182.,
 128., 52., 37., 170., 170., 61., 144., 52., 128., 71., 163.,
 150., 97., 160., 178., 48., 270., 202., 111., 85., 42., 170.,
 200., 252., 113., 143., 51., 52., 210., 65., 141., 55., 134.,
 42., 111., 98., 164., 48., 96., 90., 162., 150., 279., 92.,
 83., 128., 102., 302., 198., 95., 53., 134., 144., 232., 81.,
 104., 59., 246., 297., 258., 229., 275., 281., 179., 200., 200.,
 173., 180., 84., 121., 161., 99., 109., 115., 268., 274., 158.,
 107., 83., 103., 272., 85., 280., 336., 281., 118., 317., 235.,
 60., 174., 259., 178., 128., 96., 126., 288., 88., 292., 71.,
 197., 186., 25., 84., 96., 195., 53., 217., 172., 131., 214.,
 59., 70., 220., 268., 152., 47., 74., 295., 101., 151., 127.,
 237., 225., 81., 151., 107., 64., 138., 185., 265., 101., 137.,
 143., 141., 79., 292., 178., 91., 116., 86., 122., 72., 129.,
 142., 90., 158., 39., 196., 222., 277., 99., 196., 202., 155.,
 77., 191., 70., 73., 49., 65., 263., 248., 296., 214., 185.,
 78., 93., 252., 150., 77., 208., 77., 108., 160., 53., 220.,
 154., 259., 90., 246., 124., 67., 72., 257., 262., 275., 177.,
 71., 47., 187., 125., 78., 51., 258., 215., 303., 243., 91.,
 150., 310., 153., 346., 63., 89., 50., 39., 103., 308., 116.,
 145., 74., 45., 115., 264., 87., 202., 127., 182., 241., 66.,
 94., 283., 64., 102., 200., 265., 94., 230., 181., 156., 233.,
 60., 219., 80., 68., 332., 248., 84., 200., 55., 85., 89.,
 31., 129., 83., 275., 65., 198., 236., 253., 124., 44., 172.,
 114., 142., 109., 180., 144., 163., 147., 97., 220., 190., 109.,
 191., 122., 230., 242., 248., 249., 192., 131., 237., 78., 135.,
 244., 199., 270., 164., 72., 96., 306., 91., 214., 95., 216.,
 263., 178., 113., 200., 139., 139., 88., 148., 88., 243., 71.,
 77., 109., 272., 60., 54., 221., 90., 311., 281., 182., 321.,
 58., 262., 206., 233., 242., 123., 167., 63., 197., 71., 168.,
 140., 217., 121., 235., 245., 40., 52., 104., 132., 88., 69.,
 219., 72., 201., 110., 51., 277., 63., 118., 69., 273., 258.,
 43., 198., 242., 232., 175., 93., 168., 275., 293., 281., 72.,
 140., 189., 181., 209., 136., 261., 113., 131., 174., 257., 55.,
 84., 42., 146., 212., 233., 91., 111., 152., 120., 67., 310.,
 94., 183., 66., 173., 72., 49., 64., 48., 178., 104., 132.,
 220., 57.]), 'frame': None, 'DESCR': '.. _diabetes_dataset:\n\nDiabetes dataset\n-----\n\nTen baseli
```

Conjunto de datos del dataset de Vinos

Descripción del datasets

El conjunto de datos **Vinos (Wine)** es utilizado para **clasificación multiclase**. Contiene 178 muestras de vino, cada una descrita por 13 características numéricas que corresponden a su análisis químico (como alcohol, magnesio y fenoles). El objetivo es clasificar cada vino en una de las tres posibles bodegas o cultivos de origen.

[illegible]

INFORMACIÓN DE LOS DATOS DE ENTRADAS

```
#Mediante keys podemos entender de mejor manera lo que contiene cada Dataset
print('Información en el conjunto de datos de entrada:')
print('Cáncer de seno:')
print(dataset1.keys())
print('Iris:')
print(dataset2.keys())
print('Diabetes:')
print(dataset3.keys())
print('Vino:')
print(dataset4.keys())
```

⇒ Información en el conjunto de datos de entrada:

```
Cáncer de seno:
dict_keys(['data', 'target', 'frame', 'target_names', 'DESCR', 'feature_names', 'filename', 'data_module'])
Iris:
dict_keys(['data', 'target', 'frame', 'target_names', 'DESCR', 'feature_names', 'filename', 'data_module'])
Diabetes:
dict_keys(['data', 'target', 'frame', 'DESCR', 'feature_names', 'data_filename', 'target_filename', 'data_module'])
Vino:
dict_keys(['data', 'target', 'frame', 'target names', 'DESCR', 'feature names'])
```

El método `.keys()` para listar todas las categorías de información disponibles dentro de cada dataset, y el resultado muestra esas categorías.

Conjunto de datos del dataset de Cáncer de Seno

```
#Verificamos las características del conjunto de datos de entrada
print('Características del conjunto de datos de entrada:')
print(dataset1.DESCR)
print('Datos independientes - vectores u objetos:')
print(dataset1['data'])
print('Etiquetas de las clases o respuestas:')
print(dataset1['target'])
print('DataFrame de pandas con los datos (data) y las etiquetas (target) combinados:')
print(dataset1['frame'])
print('Nombre de las variables en la columna "target":')
print(dataset1['target_names'])
print('Nombres de cada una de las columnas de los datos:')
print(dataset1['feature_names'])
print('Ruta local del archivo .csv dentro de scikit-learn:')
print(dataset1['filename'])
print('Nombre del módulo que lo contiene:')
print(dataset1['data_module'])
```

Resultados (solo datos relevantes)

Características del conjunto de datos de entrada:

```
.. _breast_cancer_dataset:
Breast cancer wisconsin (diagnostic) dataset
-----
**Data Set Characteristics:**
:Number of Instances: 569
:Number of Attributes: 30 numeric, predictive attributes and the class
:Attribute Information:
  - radius (mean of distances from center to points on the perimeter)
  - texture (standard deviation of gray-scale values)
  - perimeter
  - area
  - smoothness (local variation in radius lengths)
  - compactness (perimeter^2 / area - 1.0)
  - concavity (severity of concave portions of the contour)
  - concave points (number of concave portions of the contour)
  - symmetry
  - fractal dimension ("coastline approximation" - 1)
The mean, standard error, and "worst" or largest (mean of the three
worst/largest values) of these features were computed for each image,
resulting in 30 features. For instance, field 0 is Mean Radius, field
10 is Radius SE, field 20 is Worst Radius.
- class:
  - WDBC-Malignant
  - WDBC-Benign
...

:Missing Attribute Values: None
:Class Distribution: 212 - Malignant, 357 - Benign
:Creator: Dr. William H. Wolberg, W. Nick Street, Olvi L. Mangasarian
:Donor: Nick Street
:Date: November, 1995
...
```

Datos independientes - vectores u objetos:

```
[[1.799e+01 1.038e+01 1.228e+02 ... 2.654e-01 4.601e-01 1.189e-01]
 [2.057e+01 1.777e+01 1.329e+02 ... 1.860e-01 2.750e-01 8.902e-02]
 [1.969e+01 2.125e+01 1.300e+02 ... 2.430e-01 3.613e-01 8.758e-02]
 ...
 [1.660e+01 2.808e+01 1.083e+02 ... 1.418e-01 2.218e-01 7.820e-02]
 [2.060e+01 2.933e+01 1.401e+02 ... 2.650e-01 4.087e-01 1.240e-01]
 [7.760e+00 2.454e+01 4.792e+01 ... 0.000e+00 2.871e-01 7.039e-02]]
```

Etiquetas de las clases o respuestas:

[illegible]

DataFrame de pandas con los datos (data) y las etiquetas (target) combinados: None

Nombre de las variables en la columna "target": ['malignant' 'benign']

Nombres de cada una de las columnas de los datos:

```
[ 'mean radius' 'mean texture' 'mean perimeter' 'mean area'
  'mean smoothness' 'mean compactness' 'mean concavity'
  'mean concave points' 'mean symmetry' 'mean fractal dimension'
  'radius error' 'texture error' 'perimeter error' 'area error'
  'smoothness error' 'compactness error' 'concavity error'
  'concave points error' 'symmetry error' 'fractal dimension error'
  'worst radius' 'worst texture' 'worst perimeter' 'worst area'
  'worst smoothness' 'worst compactness' 'worst concavity'
  'worst concave points' 'worst symmetry' 'worst fractal dimension']
```

Ruta local del archivo .csv dentro de scikit-learn: breast_cancer.csv

Nombre del módulo que lo contiene: `sklearn.datasets.data`

```
# Número de muestras (filas en data, igual a tamaño de target)
print("Número de muestras:", len(dataset1['target']))
# Número de clases únicas
print("Número de clases distintas en target:", len(np.unique(dataset1['target'])))
# Número de nombres de clases
print("Número de elementos en target_names:", len(dataset1['target_names']))
print("Número de elementos en feature_names:", len(dataset1.feature_names))
# Forma de los datos: (muestras, atributos)
print("Forma de los datos:", dataset1.data.shape)
# Verificar tipo de los datos
print("Tipo de datos de las características:", dataset1.data.dtype)
```

```

Número de muestras: 569
Número de clases distintas en target: 2
Número de elementos en target_names: 2
Número de elementos en feature_names: 30
Forma de los datos: (569, 30)
Tipo de datos de las características: float64

```

```
# Contar cuantos de cada clase hay
unique, counts = np.unique(dataset1.target, return_counts=True)
for val, count in zip(unique, counts):
    print(f"{dataset1.target_names[val]}: {count}")
```

```
➡ malignant: 212
   benign: 357
```


Conjunto de datos del dataset de Iris

```
#Verificamos las características del conjunto de datos de entrada
print('Características del conjunto de datos de entrada:')
print(dataset2.DESCR)
print('Datos independientes - vectores u objetos:')
print(dataset2['data'])
print('Etiquetas de las clases o respuestas:')
print(dataset2['target'])
print('DataFrame de pandas con los datos (data) y las etiquetas (target) combinados:')
print(dataset2['frame'])
print('Nombre de las variables en la columna "target":')
print(dataset2['target_names'])
print('Nombres de cada una de las columnas de los datos:')
print(dataset2['feature_names'])
print('Ruta local del archivo .csv dentro de scikit-learn:')
print(dataset2['filename'])
print('Nombre del módulo que lo contiene:')
print(dataset2['data_module'])
```

Resultados (solo datos relevantes)

Características del conjunto de datos de entrada:

```
.. _iris_dataset:
Iris plants dataset
-----

**Data Set Characteristics:**
:Number of Instances: 150 (50 in each of three classes)
:Number of Attributes: 4 numeric, predictive attributes and the class
:Attribute Information:
  - sepal length in cm
  - sepal width in cm
  - petal length in cm
  - petal width in cm
  - class:
    - Iris-Setosa
    - Iris-Versicolour
    - Iris-Virginica
...

:Missing Attribute Values: None
:Class Distribution: 33.3% for each of 3 classes.
:Creator: R.A. Fisher
:Donor: Michael Marshall (MARSHALL%PLU@io.arc.nasa.gov)
:Date: July, 1988

- Many, many more ...
```

Datos independientes - vectores u objetos:

```
[[5.1 3.5 1.4 0.2]
 [4.9 3.  1.4 0.2]
 [4.7 3.2 1.3 0.2]
 [4.6 3.1 1.5 0.2]
 ...
 [5.8 2.7 5.1 1.9]
 [6.8 3.2 5.9 2.3]
 [6.7 3.3 5.7 2.5]
 [6.7 3.  5.2 2.3]
 [6.3 2.5 5.  1.9]
 [6.5 3.  5.2 2. ]
 [6.2 3.4 5.4 2.3]
 [5.9 3.  5.1 1.8]]
```

Nombre del módulo que lo contiene: `sklearn.datasets.data`

```
➡ setosa: 50
   versicolor: 50
   virginica: 50
```

Conjunto de datos del dataset de Diabetes

```
#Verificamos las características del conjunto de datos de entrada
print('Características del conjunto de datos de entrada:')
print(dataset3.DESCR)
print('Datos independientes - vectores u objetos:')
print(dataset3['data'])
print('Etiquetas de las clases o respuestas:')
print(dataset3['target'])
print('DataFrame de pandas con los datos (data) y las etiquetas (target) combinados:')
print(dataset3['frame'])
print('Nombres de cada una de las columnas de los datos:')
print(dataset3['feature_names'])
print('Ruta local del archivo de datos (.csv) dentro de scikit-learn:')
print(dataset3['data_filename'])
print('Ruta local del archivo target (.csv) dentro de scikit-learn:')
print(dataset3['target_filename'])
print('Nombre del módulo que lo contiene:')
print(dataset3['data_module'])
```

Resultados (solo datos relevantes)

Características del conjunto de datos de entrada:

```
.. _diabetes_dataset:
Diabetes dataset
-----
```

...

Data Set Characteristics:

```
:Number of Instances: 442
:Number of Attributes: First 10 columns are numeric predictive values
:Target: Column 11 is a quantitative measure of disease progression one year after baseline
:Attribute Information:
  - age      age in years
  - sex
  - bmi      body mass index
  - bp       average blood pressure
  - s1       tc, total serum cholesterol
  - s2       ldl, low-density lipoproteins
  - s3       hdl, high-density lipoproteins
  - s4       tch, total cholesterol / HDL
  - s5       ltg, possibly log of serum triglycerides level
  - s6       glu, blood sugar level
```

Note: Each of these 10 feature variables have been mean centered and scaled by the standard deviation times the square root of `n\_samples` (i.e. the sum of squares of each column totals 1).

...

Datos independientes - vectores u objetos:

```
[[ 0.03807591  0.05068012  0.06169621 ... -0.00259226  0.01990749
  -0.01764613]
 [-0.00188202 -0.04464164 -0.05147406 ... -0.03949338 -0.06833155
  -0.09220405]
 [ 0.08529891  0.05068012  0.04445121 ... -0.00259226  0.00286131
  -0.02593034]
 ...
 [ 0.04170844  0.05068012 -0.01590626 ... -0.01107952 -0.04688253
   0.01549073]
 [-0.04547248 -0.04464164  0.03906215 ...  0.02655962  0.04452873
  -0.02593034]
 [-0.04547248 -0.04464164 -0.0730303 ... -0.03949338 -0.00422151
   0.00306441]]
```

Etiquetas de las clases o respuestas:

```
[151. 75. 141. 206. 135. 97. 138. 63. 110. 310. 101. 69. 179. 185.
118. 171. 166. 144. 97. 168. 68. 49. 68. 245. 184. 202. 137. 85.
131. 283. 129. 59. 341. 87. 65. 102. 265. 276. 252. 90. 100. 55.
61. 92. 259. 53. 190. 142. 75. 142. 155. 225. 59. 104. 182. 128.
52. 37. 170. 170. 61. 144. 52. 128. 71. 163. 150. 97. 160. 178.
48. 270. 202. 111. 85. 42. 170. 200. 252. 113. 143. 51. 52. 210.
65. 141. 55. 134. 42. 111. 98. 164. 48. 96. 90. 162. 150. 279.
92. 83. 128. 102. 302. 198. 95. 53. 134. 144. 232. 81. 104. 59.
246. 297. 258. 229. 275. 281. 179. 200. 200. 173. 180. 84. 121. 161.
99. 109. 115. 268. 274. 158. 107. 83. 103. 272. 85. 280. 336. 281.
118. 317. 235. 60. 174. 259. 178. 128. 96. 126. 288. 88. 292. 71.
...
265. 94. 230. 181. 156. 233. 60. 219. 80. 68. 332. 248. 84. 200.
55. 85. 89. 31. 129. 83. 275. 65. 198. 236. 253. 124. 44. 172.
114. 142. 109. 180. 144. 163. 147. 97. 220. 190. 109. 191. 122. 230.
242. 248. 249. 192. 131. 237. 78. 135. 244. 199. 270. 164. 72. 96.
306. 91. 214. 95. 216. 263. 178. 113. 200. 139. 139. 88. 148. 88.
243. 71. 77. 109. 272. 60. 54. 221. 90. 311. 281. 182. 321. 58.
262. 206. 233. 242. 123. 167. 63. 197. 71. 168. 140. 217. 121. 235.
245. 40. 52. 104. 132. 88. 69. 219. 72. 201. 110. 51. 277. 63.
118. 69. 273. 258. 43. 198. 242. 232. 175. 93. 168. 275. 293. 281.
72. 140. 189. 181. 209. 136. 261. 113. 131. 174. 257. 55. 84. 42.
146. 212. 233. 91. 111. 152. 120. 67. 310. 94. 183. 66. 173. 72.
49. 64. 48. 178. 104. 132. 220. 57.]
```

DataFrame de pandas con los datos (data) y las etiquetas (target) combinados: None

Nombres de cada una de las columnas de los datos:

```
['age', 'sex', 'bmi', 'bp', 's1', 's2', 's3', 's4', 's5', 's6']
```

Ruta local del archivo de datos (.csv) dentro de scikit-learn: diabetes_data_raw.csv.gz

Ruta local del archivo target (.csv) dentro de scikit-learn: diabetes_target.csv.gz

Nombre del módulo que lo contiene: sklearn.datasets.data

```
# Número de muestras (filas en data, igual a tamaño de target)
print("Número de muestras:", len(dataset3['target']))
# Número de clases únicas
print("Número de clases distintas en target:", len(np.unique(dataset3['target'])))
# Número de características
print("Número de elementos en feature_names:", len(dataset3.feature_names))
# Forma de los datos: (muestras, atributos)
print("Forma de los datos:", dataset3.data.shape)
# Verificar tipo de los datos
print("Tipo de datos de las características:", dataset3.data.dtype)
```

```
Número de muestras: 442
Número de clases distintas en target: 214
Número de elementos en feature_names: 10
Forma de los datos: (442, 10)
Tipo de datos de las características: float64
```

```
# Número de clases únicas
print("Número de clases distintas en target:", len(np.unique(dataset3['target'])))
```

```
Número de clases distintas en target: 214
```

Conjunto de datos del dataset de Vinos

```
#Verificamos las características del conjunto de datos de entrada
print('Características del conjunto de datos de entrada:')
print(dataset4.DESCR)
print('Datos independientes - vectores u objetos:')
print(dataset4['data'])
print('Etiquetas de las clases o respuestas:')
print(dataset4['target'])
print('DataFrame de pandas con los datos (data) y las etiquetas (target) combinados:')
print(dataset4['frame'])
print('Nombre de las variables en la columna "target":')
print(dataset4['target_names'])
print('Nombres de cada una de las columnas de los datos:')
print(dataset4['feature_names'])
```

Resultados (solo datos relevantes)

```
Características del conjunto de datos de entrada:
.. wine_dataset:
Wine recognition dataset
-----

**Data Set Characteristics:**
: Number of Instances: 178
: Number of Attributes: 13 numeric, predictive attributes and the class
: Attribute Information:
  - Alcohol
  - Malic acid
  - Ash
  - Alcalinity of ash
  - Magnesium
  - Total phenols
  - Flavanoids
  - Nonflavanoid phenols
  - Proanthocyanins
  - Color intensity
  - Hue
  - OD280/OD315 of diluted wines
  - Proline
  - class:
    - class_0
    - class_1
    - class_2

...

: Missing Attribute Values: None
: Class Distribution: class_0 (59), class_1 (71), class_2 (48)
: Creator: R.A. Fisher
: Donor: Michael Marshall (MARSHALL%PLU@io.arc.nasa.gov)
: Date: July, 1988

...

Datos independientes - vectores u objetos:
[[1.423e+01 1.710e+00 2.430e+00 ... 1.040e+00 3.920e+00 1.065e+03]
 [1.320e+01 1.780e+00 2.140e+00 ... 1.050e+00 3.400e+00 1.050e+03]
 [1.316e+01 2.360e+00 2.670e+00 ... 1.030e+00 3.170e+00 1.185e+03]
 ...
 [1.327e+01 4.280e+00 2.260e+00 ... 5.900e-01 1.560e+00 8.350e+02]
 [1.317e+01 2.590e+00 2.370e+00 ... 6.000e-01 1.620e+00 8.400e+02]
 [1.413e+01 4.100e+00 2.740e+00 ... 6.100e-01 1.600e+00 5.600e+02]]
```

[illegible]

Nombre de las variables en la columna "target": ['class_0' 'class_1' 'class_2']

```
[ 'alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash', 'magnesium', 'total_phenols', 'flavanoids',  
  'nonflavanoid_phenols', 'proanthocyanins', 'color_intensity', 'hue', 'od280/od315_of_diluted_wines',  
  'proline' ]
```

```

Número de muestras: 178
Número de clases distintas en target: 3
Número de elementos en target_names: 3
Número de elementos en feature_names: 13
Forma de los datos: (178, 13)
Tipo de datos de las características: float64

```

```

class_0: 59
class_1: 71
class_2: 48

```

GRÁFICAS DEL CONJUNTO DE DATOS

Conjunto de datos del dataset de Cáncer de Seno




Ilustración 1. Grafica en dos dimensiones del conjunto de datos de cáncer de seno.




Ilustración 2. Grafica en tres dimensiones del conjunto de datos de cáncer de seno.

Conjunto de datos del dataset de Iris




Ilustración 3. Grafica en dos dimensiones del conjunto de datos de iris.




Ilustración 4. Grafica en tres dimensiones del conjunto de datos de iris.

Conjunto de datos del dataset de Diabetes




Ilustración 5. Grafica en dos dimensiones del conjunto de datos de diabetes.




Ilustración 6. Grafica en tres dimensiones del conjunto de datos de diabetes.

Conjunto de datos del dataset de Vino




Ilustración 7. Grafica en dos dimensiones del conjunto de datos de vino.




Ilustración 8. Grafica en tres dimensiones del conjunto de datos de vino.

CONCLUSIONES

¿Cuál de los conjuntos de datos de entrada sirve para realizar la tarea de regresión?

El conjunto de datos que funciona para la tarea de regresión es el de "Diabetes".

¿Por qué? Debido a que una tarea de regresión lo que busca es predecir un valor numérico continuo. Para el caso del conjunto de datos de Diabetes busca predecir el avance de la enfermedad de manera cuantitativa un año después de la medición inicial, mientras que los otros conjuntos de datos son para tareas de clasificación.

¿Cómo lo notaron? Esto se puede notar de manera más directa al utilizar la instrucción `print(dataset.DESCR)` de Diabetes donde se especifica claramente que la variable objetivo es una "medida cuantitativa de la progresión de la enfermedad, característica correspondiente a una tarea de regresión".

Aguirre Lanto Víctor Manuel

Nunca había trabajado con este tipo de datos. La parte que más me gustó fue el proceso de visualización, ya que al graficar en 2D y 3D pude identificar patrones y agrupaciones que no son visibles solo con los números. Vi que el conjunto de Diabetes era el indicado para un problema de regresión ya que su variable era continua (Variable objetivo).

Gasca Fragoso Pedro

La práctica me enseñó la importancia de la organización en el análisis de datos. Al principio me resultó muy desordenado cargar un dataset por primera vez, pero el uso del método `.keys()` fue clave para comprender su estructura y acceder fácilmente a sus componentes.

La parte que más me gustó fue la visualización en 2D y 3D, especialmente con el dataset Iris, donde las clases se distinguían claramente en tres grupos. Gracias a esto me da cuenta de que en los datasets es muy importante mantener una buena estructura para que así la visualización revele patrones de forma efectiva y clara.


Guevara Badillo Areli Alejandra

La parte de la práctica que más me gustó y que me pareció más útil fue hacer uso del método `.keys()` para inspeccionar cada dataset. Al principio, cuando imprimía un dataset completo, aparecía un bloque enorme con información difícil de interpretar. En cambio, al usar `.keys()` nos dio una guía muy completa de las secciones disponibles, como 'data', 'target', 'features_names', etc. Esto nos ayudó mucho ya que transformó un conjunto de datos muy amplio y complicado en una estructura organizada y accesible, lo que nos permitió saber exactamente qué información podríamos solicitar y cómo hacerlo para el resto del análisis.

Montiel Toro Arael de Jesús

La parte que más me gustó fue cuando graficamos los conjuntos de datos en segunda y tercera dimensión pues hace un poco de más fácil acceso la visualización de datos para el usuario, de las cuales la que más resaltó fue la correspondiente al conjunto de datos de Iris pues estaban muy marcadas sus diferencias entre clases, estando casi separados en 3 grupos sin mezclarse lo cual no ocurrió en los otros conjuntos estando casi mezclados entre sí. Lo que más se me complicó fue la parte inicial de la práctica pues me costó un poco entender de primera mano toda la información que se imprimía a la hora de que cargáramos un dataset, sin embargo, al continuar y usar la instrucción .keys() para separar los contenidos del dataset se me facilitó de manera inmediata comprender la información que estaba visualizando en pantalla.

Ramírez Lozano Gael Martin



En esta práctica aprendí la importancia de conocer y analizar distintos conjuntos de datos antes de aplicar un método de aprendizaje automático. Cada dataset (cáncer de seno, iris, diabetes y vinos) presenta características y objetivos diferentes, lo que demuestra que no existe un único enfoque, sino que es necesario adaptar las técnicas de acuerdo con la naturaleza de los datos. Esta experiencia me permitió reforzar la comprensión sobre la preparación de la información y la forma en que las variables influyen directamente en los resultados obtenidos, lo cual es fundamental para un buen desempeño en el área de inteligencia artificial.

